

Módulo 3 – Análisis Exploratorio y Programación Estadística

Análisis Multivariado

Ciencia de Datos

Objetivos



- Explicar la diferencia entre análisis univariado, bivariado y multivariado.
- Describir el concepto de correlación entre variables.

Análisis Multivariado

El **análisis multivariado** es una rama de la estadística que se ocupa del estudio simultáneo de múltiples variables interdependientes. A diferencia del análisis univariado (que se enfoca en una sola variable) o el análisis bivariado (que examina la relación entre dos variables), el análisis multivariado examina conjuntamente cómo varias variables están relacionadas entre sí y cómo influyen en un resultado o fenómeno.

A continuación, algunos ejemplos de visualizaciones. Para lo anterior, utilizaremos el dataset Iris.

```
1 df = pd.read_csv('iris.csv')
```

```
1 df.head()
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Diagrama de Dispersión


Un diagrama de dispersión, también conocido como gráfico de dispersión o scatter plot en inglés, es una representación visual de datos que utiliza puntos para mostrar la relación entre dos variables. Cada punto en el diagrama de dispersión representa una observación en el conjunto de datos y se coloca en un plano cartesiano, donde un eje representa una variable y el otro eje representa la otra variable.

A continuación, vamos a utilizar la librería Seaborn para hacer un scatterplot en donde podamos distinguir cada especie de Iris.

```
import seaborn as sns
```

```
1 sns.scatterplot(data=df, x='petal_length', y='petal_width', hue='species')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x19d285e3688>
```



Como se puede apreciar, esta característica permite separar las distintas especies. Setosa tiene los tamaños más chicos de pétalos mientras que Virginica los más grandes.

Diagrama de Barras

- Un diagrama de barras representa datos categóricos, desplegando barras rectangulares con largos proporcionales al valor que representan.
- En este caso, representamos el promedio de cada variable para cada una de las especies. Como se puede observar, la especie Virgínica es la que posee en promedio mayor tamaño tanto de largo y ancho del pétalo, así como el largo del sépalo.

```
1 df.groupby('species').mean()
```

	sepal_length	sepal_width	petal_length	petal_width
species				
setosa	5.006	3.428	1.462	0.246
versicolor	5.936	2.770	4.260	1.326
virginica	6.588	2.974	5.552	2.026

```
1 df.groupby('species').mean().plot(kind='bar')
```

<matplotlib.axes._subplots.AxesSubplot at 0x19d26e30e48>





Diagrama de Torta

```
1 df.groupby('species').count()
```

	sepal_length	sepal_width	petal_length	petal_width
species				
setosa	50	50	50	50
versicolor	50	50	50	50
virginica	50	50	50	50

```
1 df.groupby('species').count()['petal_length'].plot(kind='pie', autopct='%.2f%%')
```

<matplotlib.axes._subplots.AxesSubplot at 0x19d2a498708>



Un diagrama de torta permite una visualización de las proporciones de alguna variable categórica.

En el siguiente ejemplo, visualizamos la proporción de cada especie respecto a la cantidad de mediciones de cada una de ellas.


Correlación

Hasta ahora nos hemos centrado en medidas de tendencia central, variabilidad y asimetría de una única variable. No obstante, en la práctica es común examinar dos o más variables conjuntamente (v.g., relación entre inteligencia y rendimiento, etc.)


En este tema, nos centraremos en la relación entre 2 variables (a partir de n observaciones apareadas) y calcularemos (en particular) un índice que nos dará el grado de relación/asociación entre ambas variables: el coeficiente de correlación.

Una **correlación** es una medida o grado de relación entre dos variables.


Representación gráfica de una relación



Relación lineal positiva




Sin relación




Relación lineal negativa

Nota: El coeficiente de correlación de Pearson mide relación LINEAL.

Representación gráfica de una relación



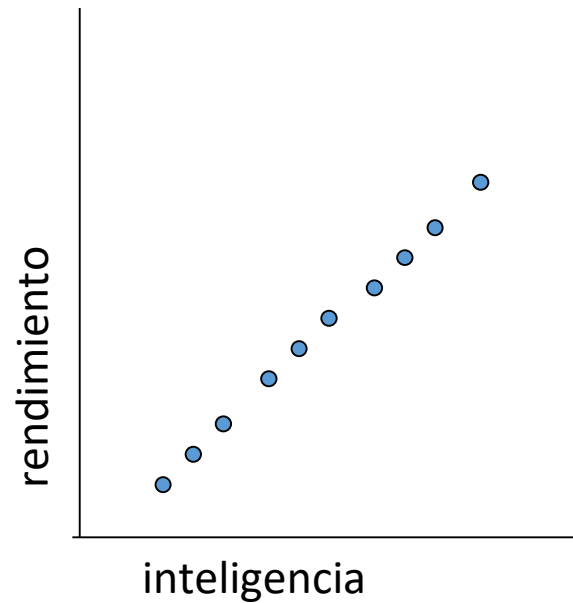
Relación lineal




Relación no lineal

Representación gráfica de una relación


Ahora necesitamos un índice que nos informe tanto del grado en que X e Y están relacionadas, y si la relación es positiva o negativa.



Relación lineal perfecta (casi perfecta)



Relación lineal fuerte/moderada



Relación lineal débil

Correlación vs Causalidad

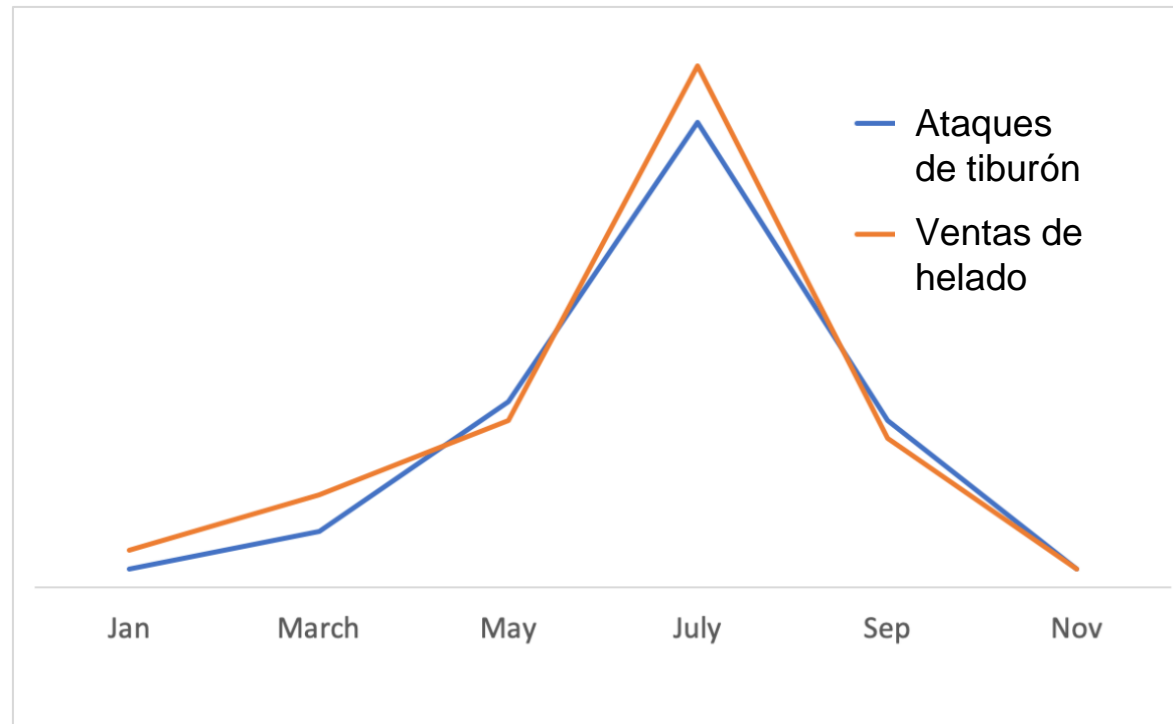
Es importante indicar que “**CORRELACIÓN NO IMPLICA CAUSALIDAD**”. El que dos variables estén altamente correlacionadas (se mueven juntas) no implica necesariamente que X causa Y ni que Y causa X.

- Esa es una de las razones empleadas por las tabaqueras en el tema de la correlación entre cáncer de pulmón y el hecho de fumar.

Una correlación fuerte puede indicar causalidad, pero también es probable que existan otras explicaciones:

- Puede ser el resultado del azar: las variables parecen estar relacionadas, pero en realidad no hay una relación subyacente.
- Puede haber una tercera variable al acecho que haga que la relación parezca más fuerte (o más débil) de lo que realmente es.


Correlación y Causalidad



!!!Correlación NO implica causalidad !!!

Correlación y Causalidad

Número de personas que murieron ahogadas en su piscina



Películas en la que aparece Nicolas Cage

Correlaciones Espurias

<https://tylervigen.com/spurious-correlations>

Covarianza

- La covarianza emplea el producto de las puntuaciones diferencias de X e Y :
- En el caso pendiente positiva, la covarianza será un valor positivo, y en el caso pendiente negativa, la covarianza será un valor negativo. Por tanto, la covarianza nos da una idea de si la relación entre X e Y es positiva o negativa.

Problema: la covarianza no es un índice acotado (v.g., cómo interpretar una covarianza de 6 en términos del grado de asociación), y no tiene en cuenta la variabilidad de las variables. Por eso se emplea el siguiente índice:

$$s_{xy} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n}$$

Coeficiente de correlación (lineal) de Pearson

El coeficiente de correlación de Pearson parte de la covarianza:

$$r_{xy} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n \cdot s_x \cdot s_y} \quad r_{xy} = \frac{s_{xy}}{s_x \cdot s_y}$$

$$r_{xy} = \frac{n \sum xy - \sum x \sum y}{\sqrt{\left(n \sum x^2 - (\sum x)^2\right) \left(n \sum y^2 - (\sum y)^2\right)}}$$

A continuación, veremos varias propiedades del índice.

Coeficiente de correlación (lineal) de Pearson

Propiedad 1: El índice de correlación de Pearson no puede valer menos de -1 ni más de +1.

- Un índice de correlación de Pearson de -1 indica una relación lineal negativa perfecta.
- Un índice de correlación de Pearson de +1 indica una relación lineal positiva perfecta.
- Un índice de correlación de Pearson de 0 indica ausencia de relación lineal. Observa que un valor cercano a 0 del índice no implica que no haya algún tipo de relación no lineal: el índice de Pearson mide relación lineal.

Coeficiente de correlación (lineal) de Pearson


Propiedad 2: El índice de correlación de Pearson (en valor absoluto) no varía cuando se transforman linealmente las variables.

Por ejemplo, la correlación de Pearson entre la temperatura (en grados celsius) y el nivel de depresión es la misma que la correlación entre la temperatura (medida en grados Fahrenheit) y el nivel de depresión.

Coeficiente de correlación (lineal) de Pearson

➤ Interpretación:

- Tener en cuenta qué es lo que estamos midiendo para poder interpretar cuán grande es la relación entre las variables bajo estudio. En muchos casos, depende del área bajo estudio.
- En todo caso, es muy importante efectuar el diagrama de dispersión. Por ejemplo, en el caso de la izquierda, es claro que no hay relación entre inteligencia y rendimiento. Sin embargo, si calculamos el índice de correlación de Pearson nos dará un valor muy elevado, causado por la puntuación atípica en la esquina superior derecha.



Otros coeficientes: variables semi-cuantitativas

Es posible obtener medidas del grado de relación de variables cuando éstas no sean cuantitativas.

Caso en que las variables X e Y sean ordinales:

Cuando tenemos variables con escala ordinal, podemos establecer el orden entre los valores, pero no sabemos las distancias entre los valores. (Si supiéramos la distancia entre los valores ya estaríamos al menos en una escala de intervalo)

Podemos calcular:

- Coeficiente de correlación de Spearman
- Coeficiente de correlación de Kendall.

Coeficiente de correlación de Spearman

El coeficiente de Spearman es un caso especial del coeficiente de correlación de Pearson aplicada a dos series de los n primeros números naturales (cuando no hay empates; si hay –muchos- empates hay otra fórmula).

$$r_s = 1 - \frac{6 \cdot \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

d_i es la diferencia entre el valor ordinal en X y el valor ordinal en Y del sujeto i

Coeficiente de correlación de Spearman

$$r_s = 1 - \frac{6 \cdot \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

d_i es la diferencia entre el valor ordinal en X y el valor ordinal en Y del sujeto i

Se encuentra acotado, como el coeficiente de Pearson entre -1 y +1.

Un coeficiente de Spearman de +1 quiere decir que el que es primero en X es primero en Y, el que es segundo en X es segundo en Y, etc.

Un coeficiente de Spearman de -1 quiere decir que el que es primero en X es último en Y, el segundo en X es el penúltimo en Y, etc.

The background of the slide features a grayscale, high-contrast image of a mountain peak. The mountain's surface is covered in a dense, repeating pattern of small, dark, curved lines that resemble ripples or a textured fabric. A bright, white, diagonal line runs across the upper part of the mountain, possibly representing a snowfield or a light reflection. A solid green rectangular banner with rounded corners is positioned horizontally across the middle of the image, containing the text 'Dudas y consultas' in white.

Dudas y consultas

Fin Presentación