KIBERNUM
IT Academy

Módulo 3 – Análisis Exploratorio y Programación Estadística

Análisis Visual Librería Matplotlib

Ciencia de Datos

Librería Matplotlib

- Es una librería para para análisis visual.
- Muy popular en proyectos de ciencia de datos y se complementa muy bien con Pandas y NumPy.
- Posee buen performance en su ejecución.
- Viene en la distribución Anaconda.

Web Matplotlib

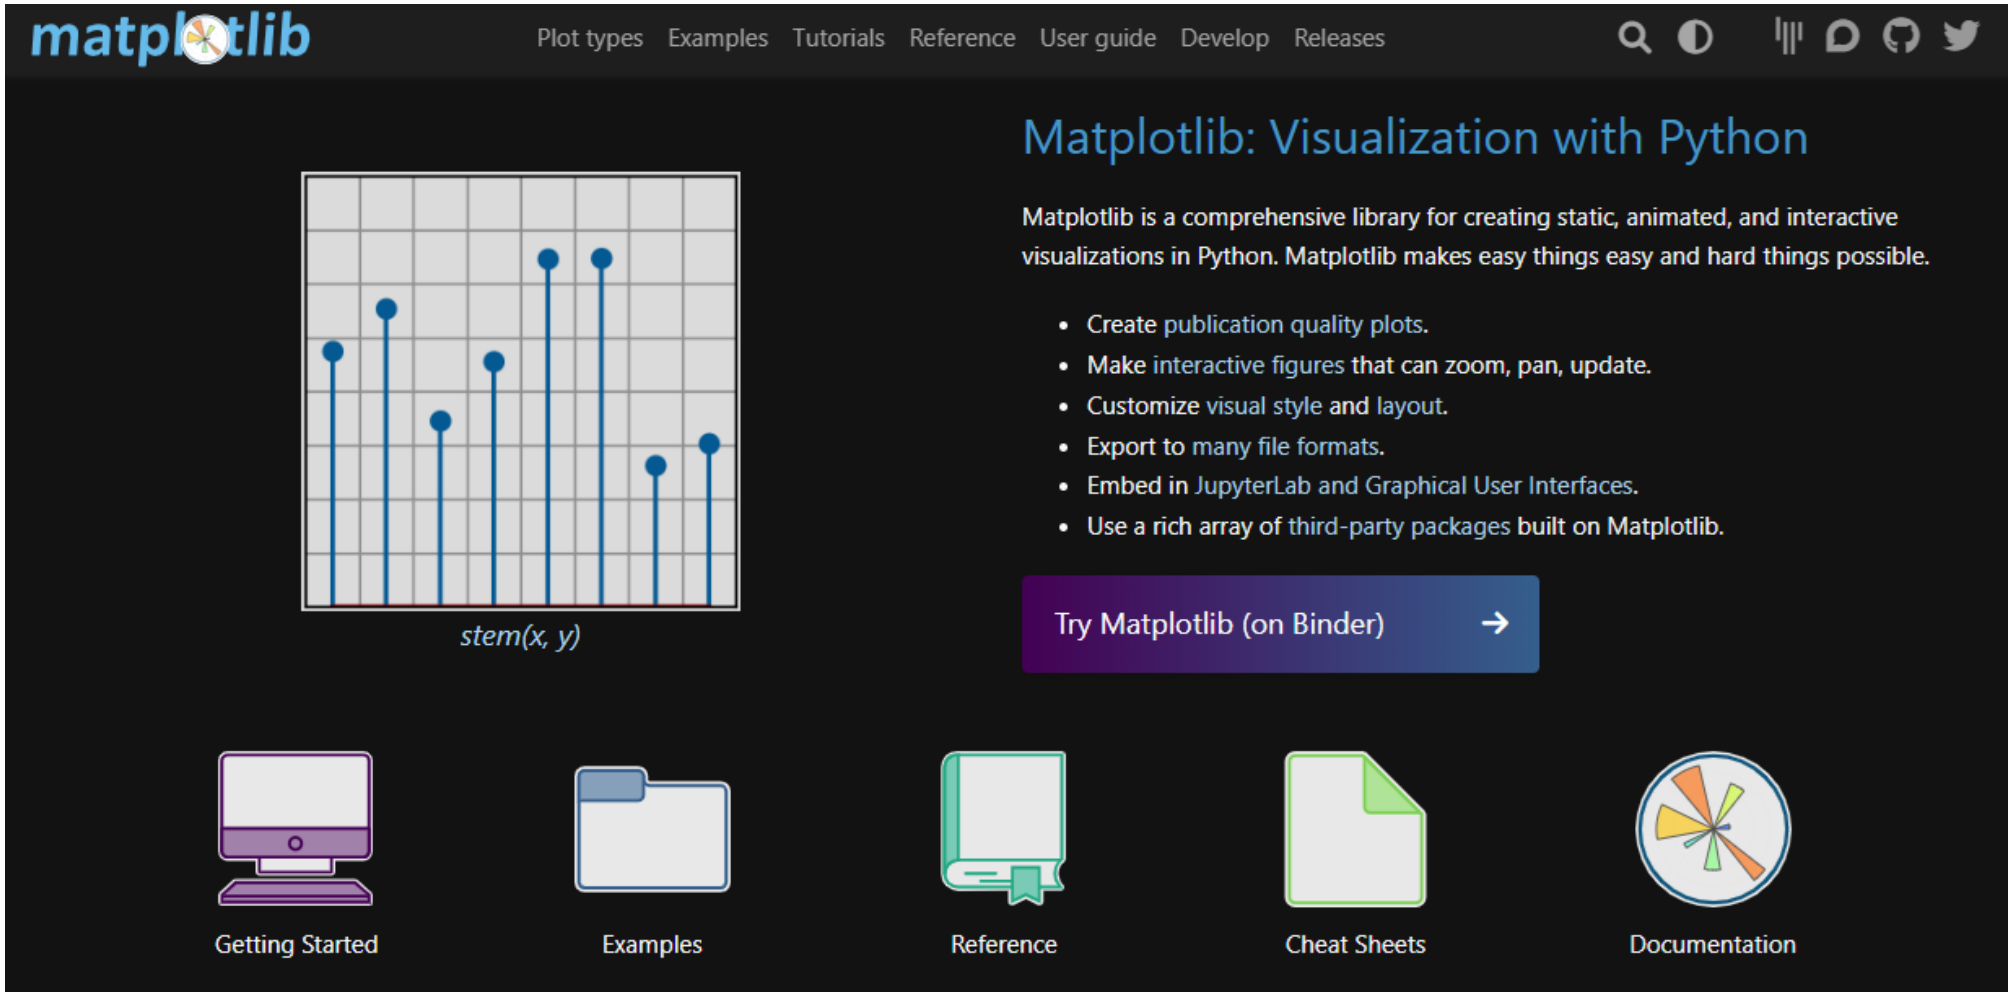

https://matplotlib.org

Librería Matplotlib

- La **librería Matplotlib**, puede ser utilizada para programar los gráficos y visualizaciones que necesitemos. Esta librería tiene dos mecanismos para ser programada:

  1. Mediante la utilización de **funciones del módulo PyPlot.**
  2. Mediante el modelo de **orientación a objetos.**

- El **módulo PyPlot**, ofrece mayor simpleza en la programación, puesto que utiliza funciones prefabricadas para facilitar la programación de un gráfico. Sin embargo, si es requerido un mayor nivel de personalización, ahí se hace necesario conocer el modelo de orientación a objetos que provee la librería.

  En esta presentación conoceremos ambos enfoques.

Set de Datos

	A	B	C	D
1	Grupo de edad	Sexo	Fecha	Contagiados
2	00 - 04 años	M	2020-03-25	4
3	05 - 09 años	M	2020-03-25	2
4	10 - 14 años	M	2020-03-25	7
5	15 - 19 años	M	2020-03-25	8
6	20 - 24 años	M	2020-03-25	25
7	25 - 29 años	M	2020-03-25	61
8	30 - 34 años	M	2020-03-25	88
9	35 - 39 años	M	2020-03-25	72
10	40 - 44 años	M	2020-03-25	62
11	45 - 49 años	M	2020-03-25	47
12	50 - 54 años	M	2020-03-25	28
13	55 - 59 años	M	2020-03-25	30
14	60 - 64 años	M	2020-03-25	18
15	65 - 69 años	M	2020-03-25	14
16	70 - 74 años	M	2020-03-25	16
17	75 - 79 años	M	2020-03-25	8
18	80 y más años	M	2020-03-25	6
19	00 - 04 años	F	2020-03-25	6
20	05 - 09 años	F	2020-03-25	4
21	10 - 14 años	F	2020-03-25	2
22	15 - 19 años	F	2020-03-25	12
23	20 - 24 años	F	2020-03-25	43
24	25 - 29 años	F	2020-03-25	65
25	30 - 34 años	F	2020-03-25	80
26	35 - 39 años	F	2020-03-25	79

Para este ejemplo, utilizaremos el set de datos de contagios totales de covid-19 por grupo etario, disponible en el repositorio del Ministerio de Ciencias.

KIBERNUM

Importando la Librería

```
In [2]: import matplotlib.pyplot as plt

In [3]: %matplotlib inline
```

Variable de ambiente para desplegar en línea los gráficos en el entorno Jupyter.

Obtención de los Datos

```
df = pd.read_csv('datos-covit-etareo.csv')
df
```

	Grupo de edad	Sexo	Fecha	Contagiados
0	00 - 04 años	M	2020-03-25	4
1	05 - 09 años	M	2020-03-25	2
2	10 - 14 años	M	2020-03-25	7
3	15 - 19 años	M	2020-03-25	8
4	20 - 24 años	M	2020-03-25	25
...	...	...	...	...
1593	60 - 64 años	F	2020-06-01	2407
1594	65 - 69 años	F	2020-06-01	1547
1595	70 - 74 años	F	2020-06-01	1178
1596	75 - 79 años	F	2020-06-01	880
1597	80 y más años	F	2020-06-01	1525

1598 rows × 4 columns

Para trabajar en este ejemplo, utilizaremos las cifras del COVID-19 en Chile por rango etario.

Obtención de los Datos

```
df2 = df.groupby('Fecha').sum()
df2.reset_index(inplace=True)
df2.drop('Fecha', axis=1, inplace=True)
df2.head(10)
```

	Contagiados
0	1012
1	1252
2	1434
3	1723
4	1906
5	2088
6	2373
7	2744
8	2938
9	3398

Ahora realizamos algunas adecuaciones a nuestro DataFrame para ejemplificar de mejor manera.

Nuestro Primer Gráfico

Nuestro primer gráfico lo construiremos utilizando las funciones pyplot de matplotlib.

```
plt.plot(df2)
plt.xlabel('Día')
plt.ylabel('Cantidad de Contagiados')
plt.title('Evolución Contagiados')
plt.show()
```

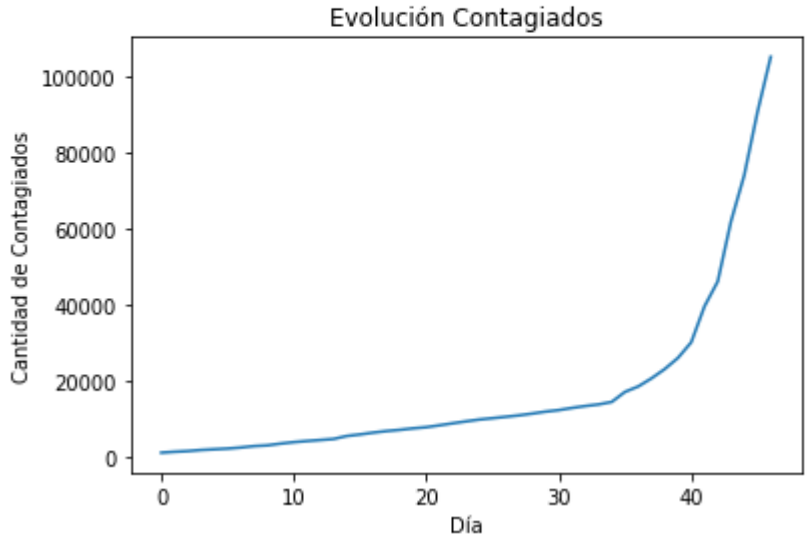

La instrucción plt.show() puede ser omitida en los notebooks jupyter, en otro entorno sí debe incluirse.

Creando sub gráficos

Cant. filas

Cant. cols

Índice de la posición del gráfico en la grilla

```
plt.subplot(1,2,1)
plt.plot(df_m, 'g')
plt.title('Contagios Hombres')

plt.subplot(1,2,2)
plt.plot(df_f, 'r')
plt.title('Contagios Mujeres')

plt.tight_layout()
```

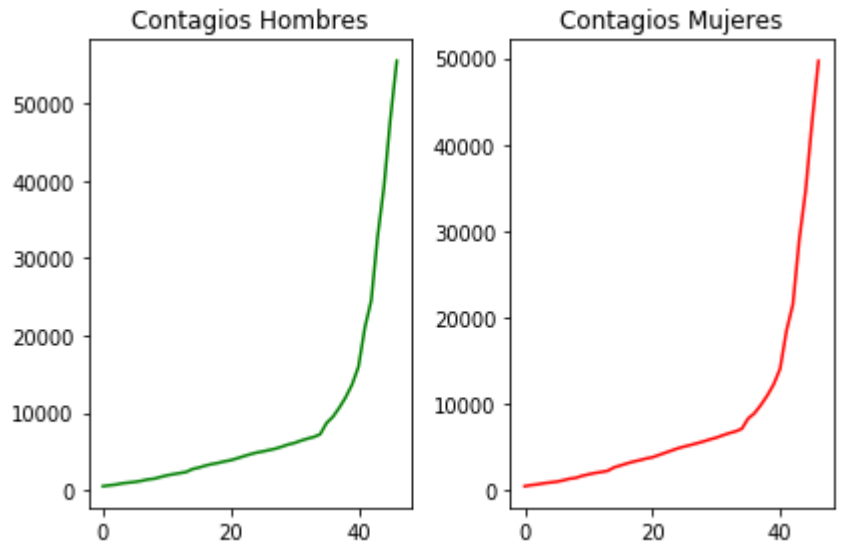

Nota: df_m y df_f son datasets que previamente han sido filtrados y agrupados convenientemente.

Tamaño de la Figura y DPI

```
# se cambia el tamaño de la figura y el numero de puntos por pulgada
plt.figure(figsize=(8,4), dpi=100)

plt.plot(x, y) # se grafica una linea de color azul

plt.xlabel('Nombre del eje X') # definir el nombre del eje X
plt.ylabel('Nombre del eje Y') # definir el nombre del eje Y
plt.title('Titulo de la grafica'); # definir el titulo de la grafica

# agrego ; al final del ultimo comando para solo mostrar la grafica
# plt.show() no es necesario en jupyter notebook
```

Matplotlib permite especificar la relación de aspecto, el DPI y el tamaño de la figura cuando se crea el objeto Figure. Puede usar los argumentos de las palabras clave figsize y dpi. No es necesario poner las dos.

- **figsize** es una tupla del ancho y alto de la figura en pulgadas
- **dpi** es el punto por pulgada (pixel por pulgada).

Escala Logarítmica

Mediante la función **yscale()** se puede definir que el eje y tenga una escala logarítmica.

```
plt.figure(figsize=(10,4))

plt.subplot(1,2,1)
plt.plot(x, x**2, x, np.exp(x))
plt.title("escala Normal")

plt.subplot(1,2,2)
plt.plot(x, x**2, x, np.exp(x))
plt.yscale("log")
plt.title("Escala Logaritmica(y)");

plt.tight_layout() # para que no se superpongan las graficas
```

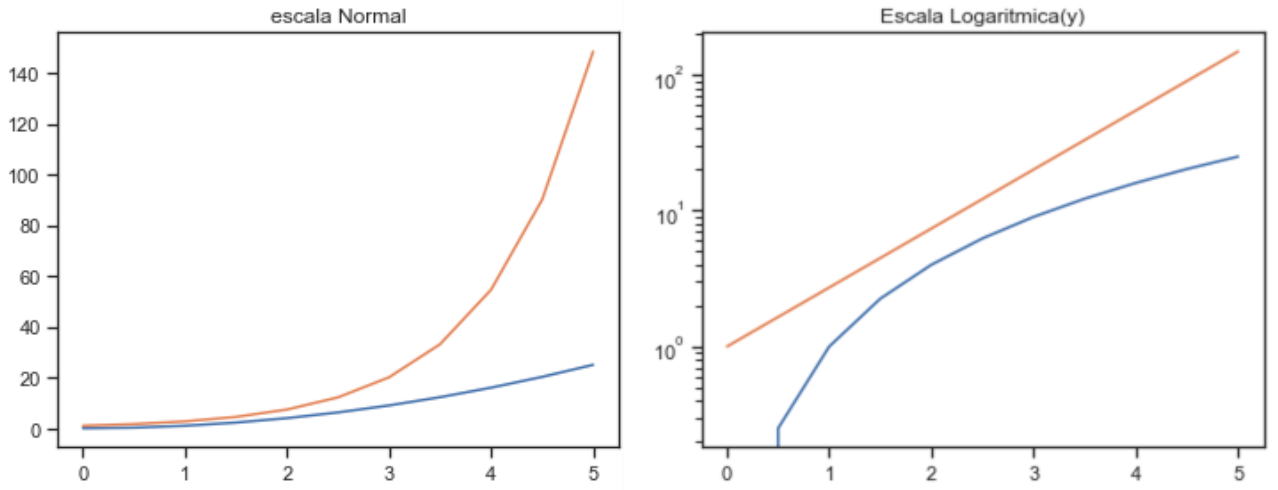

Anotaciones de Texto

Anotar texto en figuras matplotlib se puede hacer usando la función text. Es compatible con el formato LaTeX al igual que los textos y títulos de la etiqueta del eje:

```
# Datos para graficar
xx = np.linspace(-0.75, 1., 100)

plt.plot(xx, xx**2, xx, xx**3)
plt.title("Plot con anotaciones")

# Anotacion 1
plt.text(0.15, 0.2, r"$y=x^2$", fontsize=20, color="blue")
#Anotacion 2
plt.text(0.65, 0.1, r"$y=x^3$", fontsize=20, color="green");
```

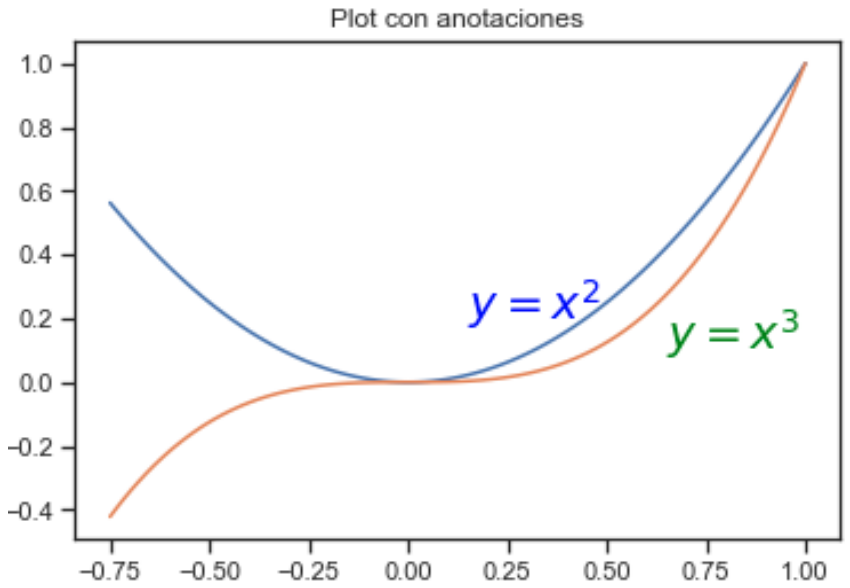

Orientación a Objetos

Ahora crearemos un gráfico utilizando orientación a objetos.

```
fig = plt.figure()
axes = fig.add_axes([0,0,1,1])
axes.plot(df2)
axes.set_xlabel('Día')
axes.set_ylabel('Contagiados')
axes.set_title('Total Contagiados')
```

```
Text(0.5, 1.0, 'Total Contagiados')
```

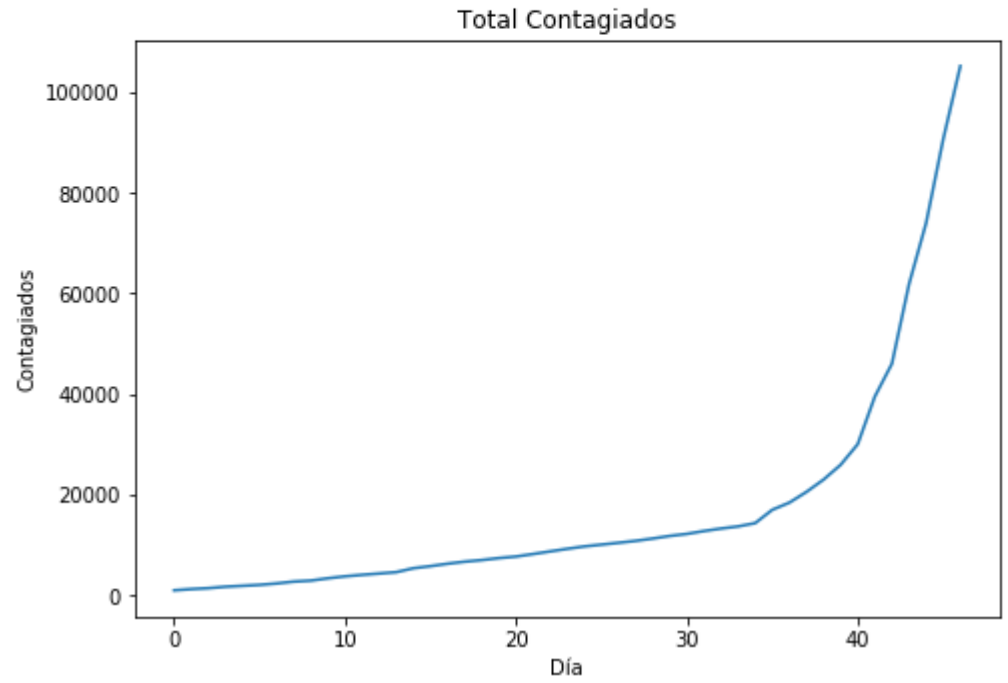

Ubicando la posición de los ejes

```
fig = plt.figure()
axes1 = fig.add_axes([0, 0, 0.45, 1])
axes2 = fig.add_axes([0.55, 0, 0.45, 0.45])
axes3 = fig.add_axes([0.55, 0.55, 0.45, 0.45])
axes1.plot(df2)
axes2.plot(df_m, 'r')
axes3.plot(df_f, 'g')
axes1.set_title('Total Contagios')
axes2.set_title('Hombres')
axes3.set_title('Mujeres')
```

```
Text(0.5, 1.0, 'Mujeres')
```

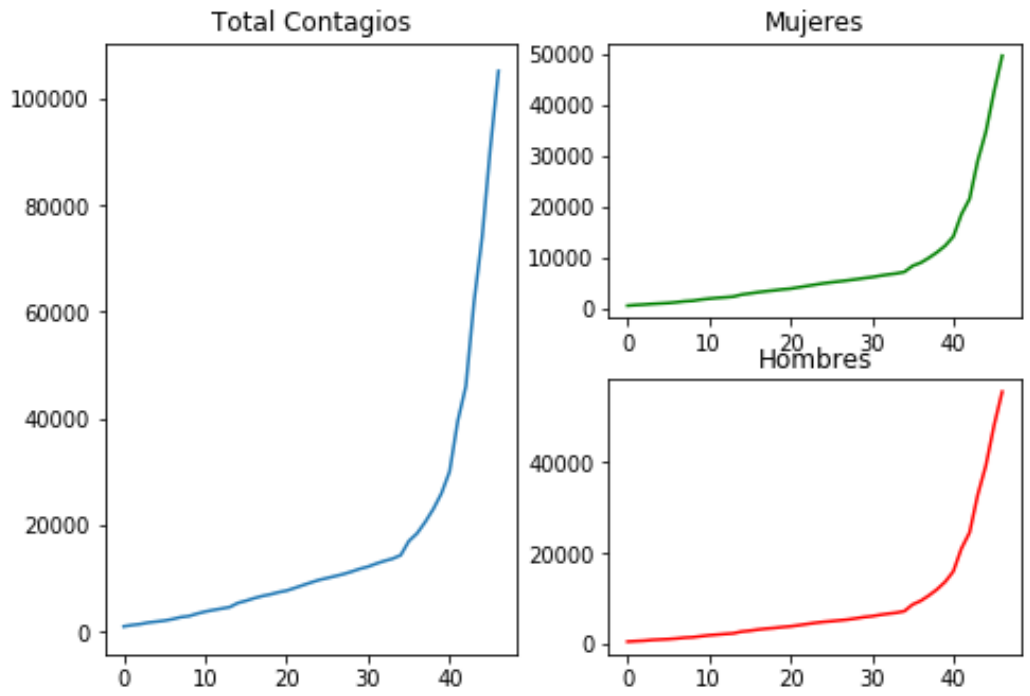

Nótese lo que sucede cuando modificamos los valores de los ejes.

Ubicando la posición de los ejes

Nótese lo que sucede cuando modificamos los valores de los ejes.

Crea canvas vacío

```
In [42]: fig = plt.figure()
         axes1 = fig.add_axes([0.1,0.1,0.8,0.8])
         axes2 = fig.add_axes([0.2,0.5,0.4,0.3])
         axes3 = fig.add_axes([0.6,0.2,0.2,0.2])
```

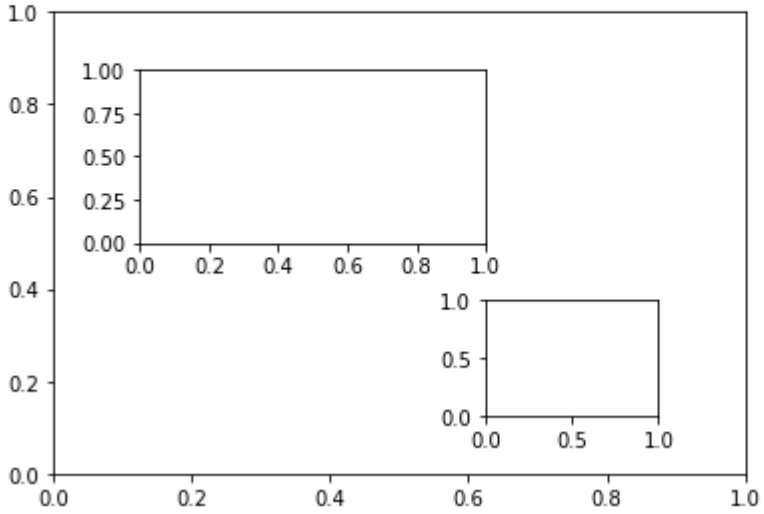

Definen la ubicación relativa del gráfico en el canvas.

[a, b, c, d]

LEFT

BOTTOM

TOP

RIGHT

Los valores van entre 0 y 1 (0% y 100%)

KIBERNUM

Subplots

- Volvamos a crear subgráficos, ahora utilizando orientación a objetos.

```
fig, axes = plt.subplots(nrows=3, ncols=3)
```

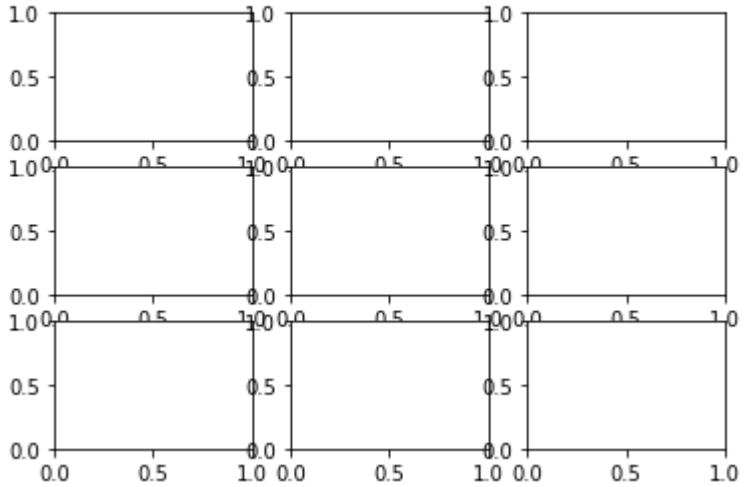

- Para organizar el espacio entre cada gráfico se usa el método **tight_layout()**

```
fig, axes = plt.subplots(nrows=3, ncols=3)
fig.tight_layout()
```

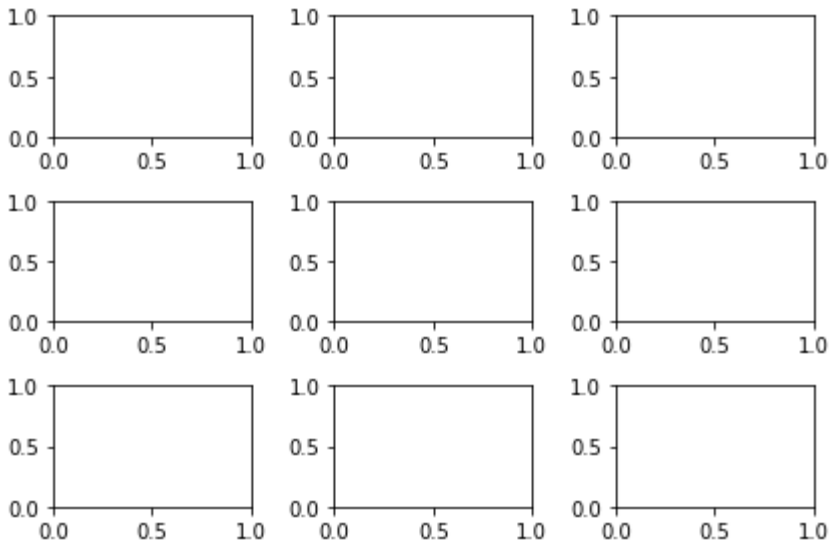

Subplots

- Nótese la forma empaquetada que retorna el método subplots que llena una tupla de datos (fig y axes).

```
fig, axes = plt.subplots(nrows=2, ncols=1)
axes[0].plot(df_m, 'r')
axes[1].plot(df_f, 'g')
fig.tight_layout()
```

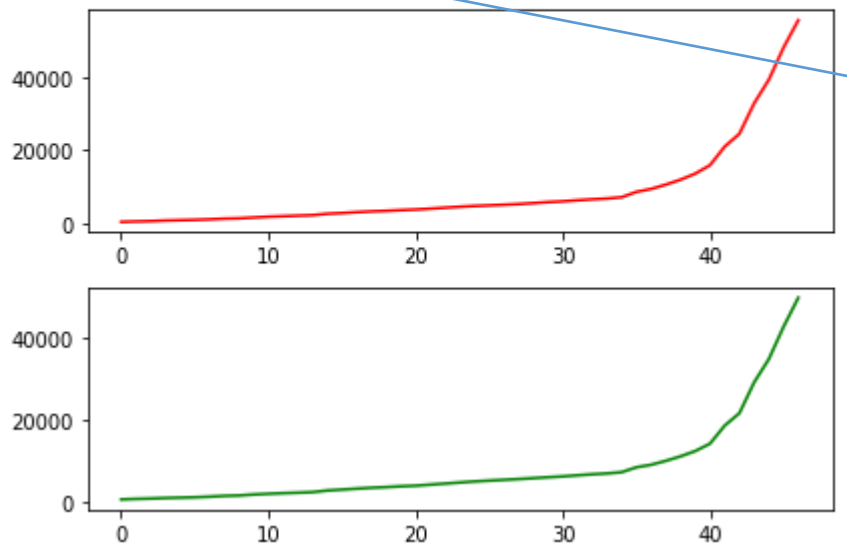

Axes es un arreglo de ejes, por lo tanto, podemos referenciar cada elemento con la notación []

Tamaño del gráfico

- Con el parámetro figsize, que recibe una tupla, podemos especificar las dimensiones de la figura (pulgadas).

```
fig = plt.figure(figsize=(8,2))
axe = fig.add_axes([0,0,1,1])
axe.plot(x,y)
```

```
[<matplotlib.lines.Line2D at 0x169764e1780>]
```

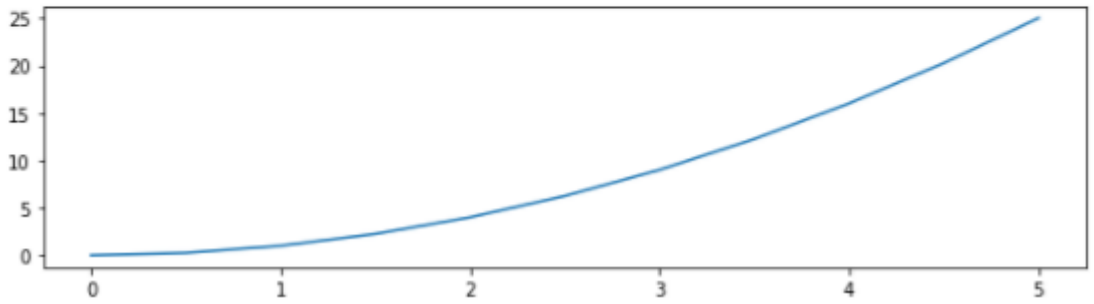


```
fig, axes = plt.subplots(nrows=2, ncols=1, figsize=(8,2))
axes[0].plot(x,y)
axes[1].plot(y,x)
plt.tight_layout()
```

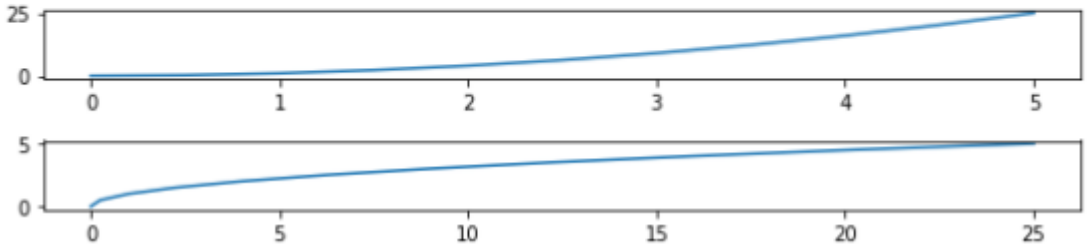

Lo mismo se puede especificar al realizar subgráficos.

Gráficos con más de una serie

- Nótese la forma empaquetada que retorna el método subplots que llena una tupla de datos (fig y axes).

Ploteamos en el mismo juego de ejes

```
fig = plt.figure(figsize=(8,2))
axe = fig.add_axes([0,0,1,1])
axe.plot(df_m)
axe.plot(df_f)
```

```
[<matplotlib.lines.Line2D at 0x1b7ef3d8488>]
```

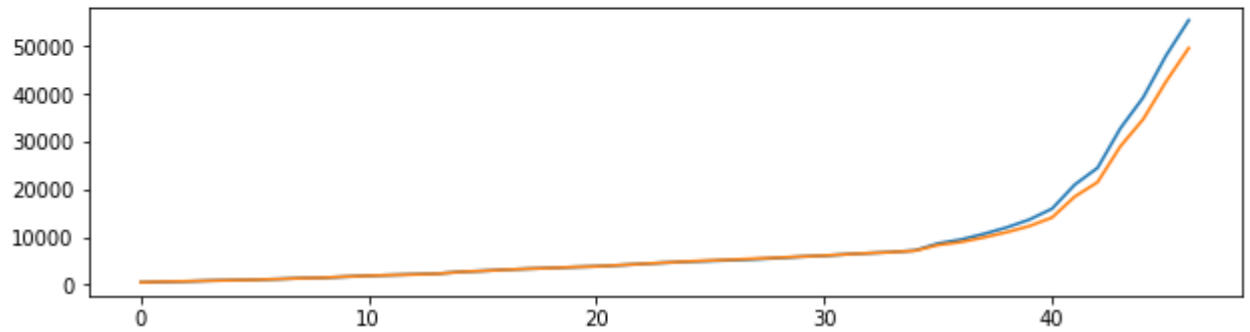

Agregar leyendas

- Podemos crear un gráfico con múltiples líneas y agregar un cuadro de leyendas.

```
fig = plt.figure(figsize=(8,2))
axe = fig.add_axes([0,0,1,1])
axe.plot(df_m, label='Hombres')
axe.plot(df_f, label='Mujeres')
axe.legend(loc=0)
```

```
<matplotlib.legend.Legend at 0x1b7f117d688>
```

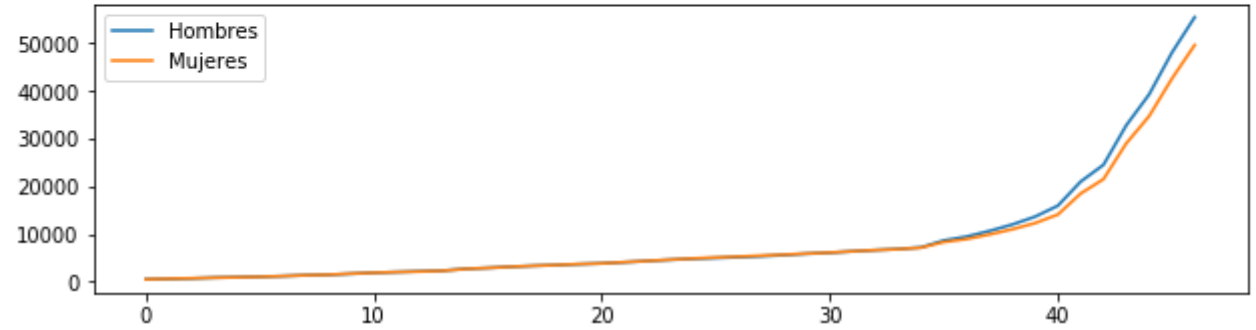

Guardar un gráfico

- Se pueden especificar distintas extensiones (png, jpg, gif) y se puede especificar la resolución (dpi) de la imagen.

```
fig.savefig('mi_figura.png', dpi=200)
```

Apariencia

Podemos variar el color del gráfico, el ancho y el estilo de la línea.

red, green, orange, blue, purple, black…
también puede ser el código RGB

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.plot(df_m, label='Hombres', color='blue', linewidth=3, linestyle='dashed')
axe.plot(df_f, label='Total', color='#FF2200', lw=1, ls='--', marker='o')  #o,s,+,1
axe.legend(loc=0)
# otros parámetros
# markersize, markerfacecolor, markeredgewidth, markeredgecolor
```

```
<matplotlib.legend.Legend at 0x1b7f120b808>
```

o, s, +, 1

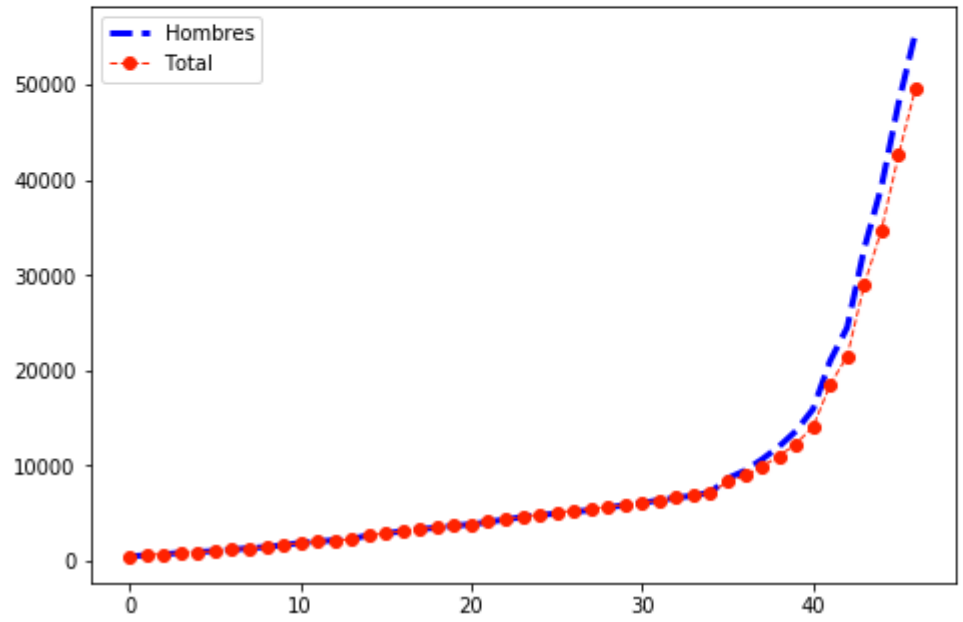

Otros parámetros:
Markersize
Markerfacecolor
Markeredgewidth
Markeredgecolor

Límites

Podemos setear el rango de valores de los ejes con el cual limitar su despliegue.

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.plot(df_m, label='Hombres', color='blue')
axe.plot(df_f, label='Total', color='red')
axe.set_xlim([20,50])
axe.set_ylim([1000,20000])
```

```
(1000, 20000)
```

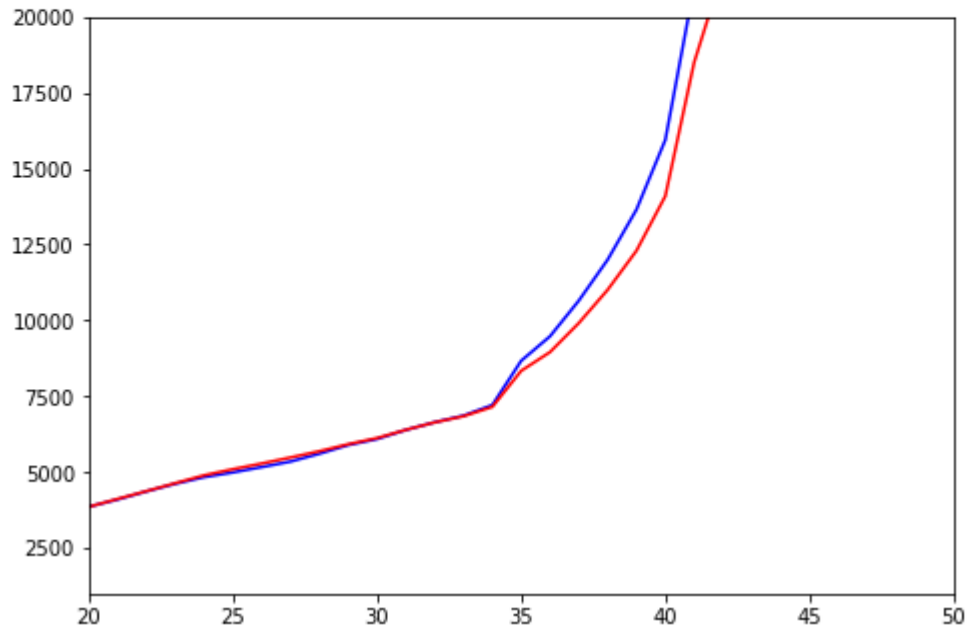

Tipos de gráfico

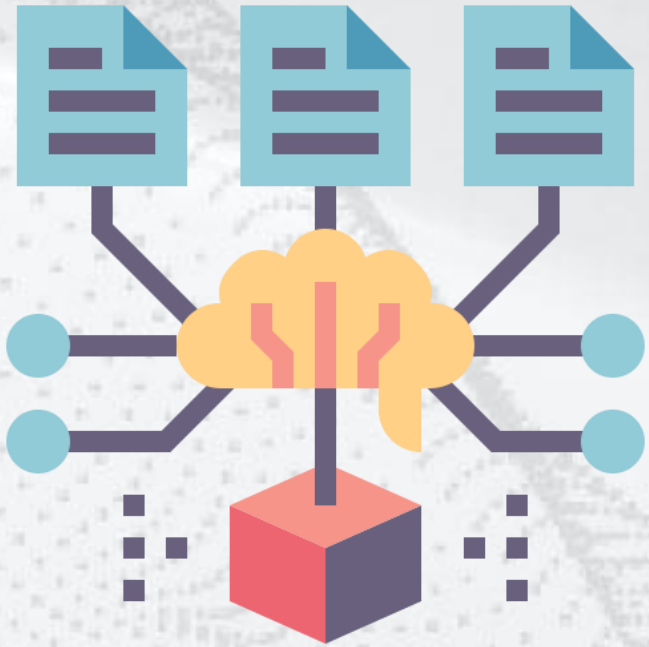

Otros tipos de gráfico

Para ilustrar algunos ejemplos, vamos a recurrir al dataset de Salarios de San Francisco:

```
df = pd.read_csv('Salaries.csv')
df.head(2)
```

	Id	EmployeeName	JobTitle	BasePay	OvertimePay	OtherPay	Benefits	TotalPay	TotalPayBenefits	Year	Notes	Agency	Status
0	1	NATHANIEL FORD	GENERAL MANAGER-METROPOLITAN TRANSIT AUTHORITY	167411.18	0.00	400184.25	NaN	567595.43	567595.43	2011	NaN	San Francisco	NaN
1	2	GARY JIMENEZ	CAPTAIN III (POLICE DEPARTMENT)	155966.02	245131.88	137811.38	NaN	538909.28	538909.28	2011	NaN	San Francisco	NaN

Histograma

El siguiente es un histograma, que muestra la frecuencia de los valores en cada intervalo.

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.hist(df['BasePay'].dropna(), bins=20)
```

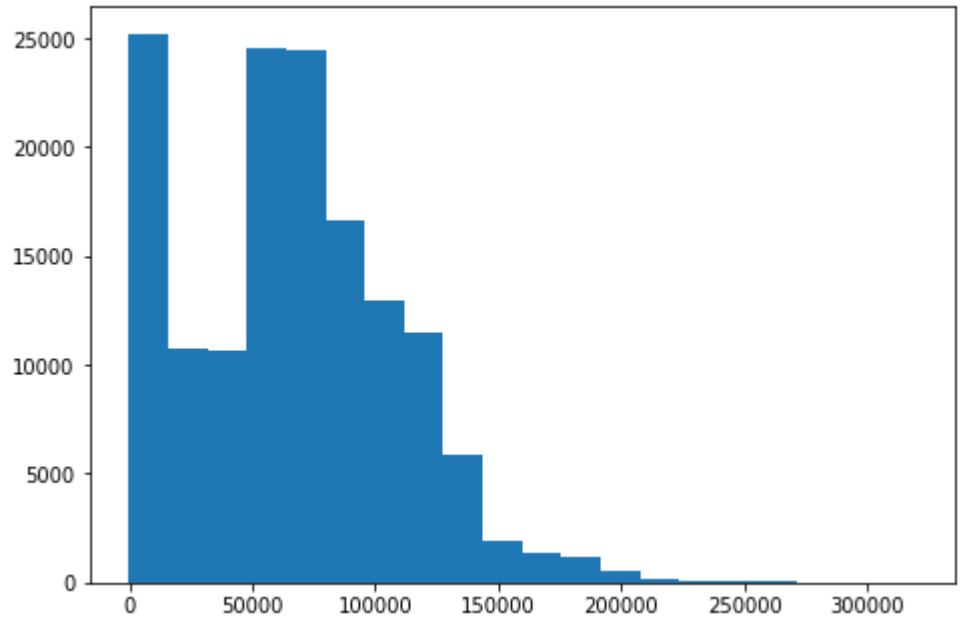

Diagrama de caja

El siguiente es un diagrama de caja, que muestra el mínimo, máximo, percentil 25, 50 y 75.

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.boxplot(df['BasePay'].dropna())
```

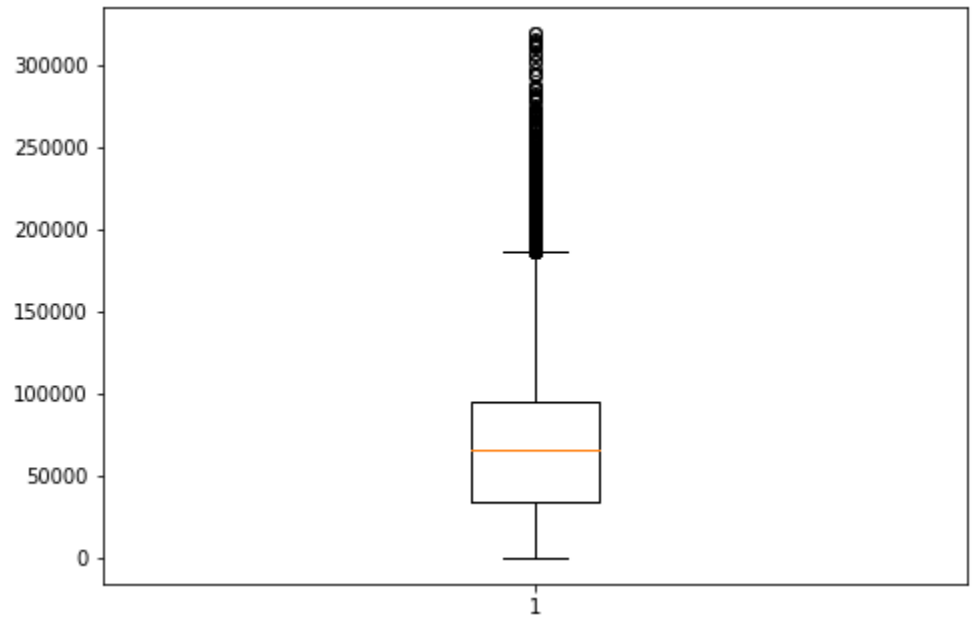

Diagrama de dispersión

El siguiente es un diagrama de dispersión (scatterplot).

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.scatter(df['BasePay'],df['Benefits'])
axe.set_xlabel('Base Pay')
axe.set_ylabel('Benefits')
```

```
Text(0, 0.5, 'Benefits')
```

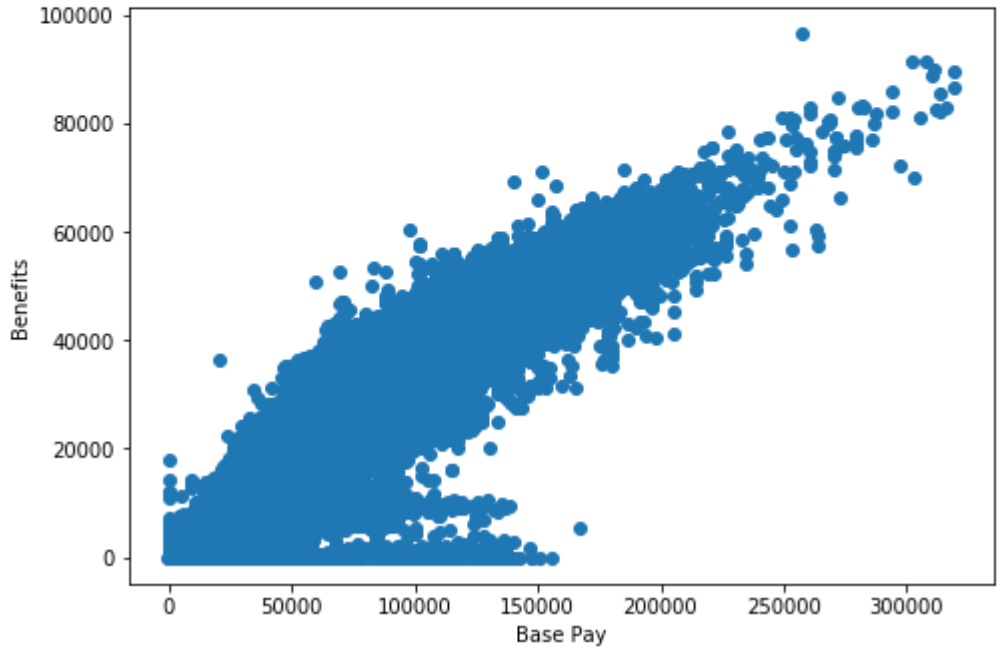

Diagrama de Barras

Volvamos a nuestro ejemplo de Covid en Chile y construyamos un diagrama de barras.

Un poco de wrangling para este ejemplo:

```
df3 = df.groupby('Grupo de edad').sum()
df3.reset_index(inplace=True)
df3.head(2)
```

	Grupo de edad	Contagiados
0	00 - 04 años	14898
1	05 - 09 años	11246

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.bar(df3['Grupo de edad'].values, df3['Contagiados'].values)
axe.tick_params(axis='x', labelrotation=90)
```

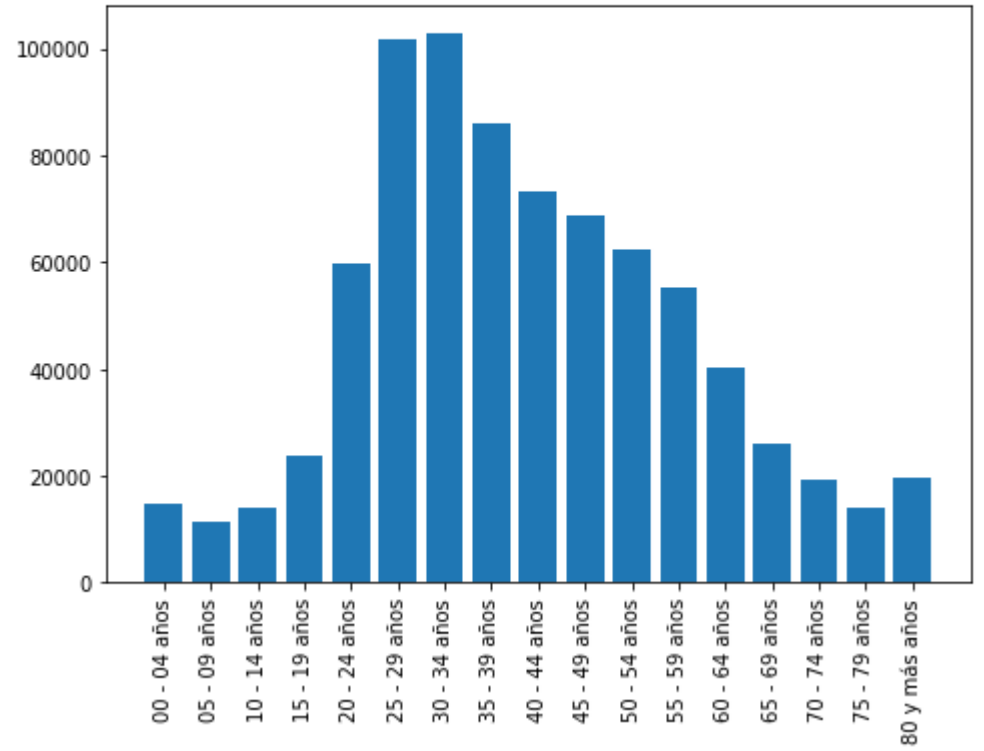

KIBERNUM

Diagrama de torta

Construyamos un diagrama de Torta:

```
df4 = df.groupby(['Grupo de edad']).sum()
df4.reset_index(inplace=True)
df4.head(2)
```

	Grupo de edad	Contagiados
0	00 - 04 años	14898
1	05 - 09 años	11246

```
fig = plt.figure()
axe = fig.add_axes([0,0,1,1])
axe.pie(df4['Contagiados'].values, labels=df4['Grupo de edad'].values, autopct='%1.1f%%')
axe.tick_params(axis='x', labelrotation=90)
```

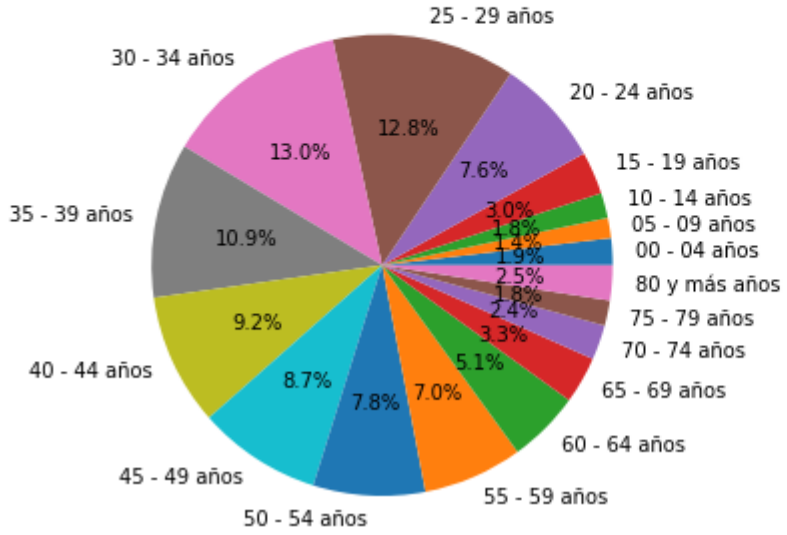

KIBERNUM

Estilos

KIBERNUM

Estilos disponibles

Un estilo es una combinación de colores y formas que puede ajustarse un gráfico. A continuación, obtenemos el listado de estilos disponibles en el entorno.

Con esto, podemos fijar una apariencia pre-establecida a todos los gráficos que construyamos con la librería matplotlib.

```
plt.style.available
```

```
['bmh',
 'classic',
 'dark_background',
 'fast',
 'fivethirtyeight',
 'ggplot',
 'grayscale',
 'seaborn-bright',
 'seaborn-colorblind',
 'seaborn-dark-palette',
 'seaborn-dark',
 'seaborn-darkgrid',
 'seaborn-deep',
 'seaborn-muted',
 'seaborn-notebook',
 'seaborn-paper',
 'seaborn-pastel',
 'seaborn-poster',
 'seaborn-talk',
 'seaborn-ticks',
 'seaborn-white',
 'seaborn-whitegrid',
```

Estilos disponibles

```
plt.style.use('fivethirtyeight')
```

```
fig = plt.figure(figsize=(8,3))
axe = fig.add_axes([0,0,1,1])
axe.bar(df4['Grupo de edad'].values, df4['Contagiados'].values)
axe.tick_params(axis='x', labelrotation=90)
```

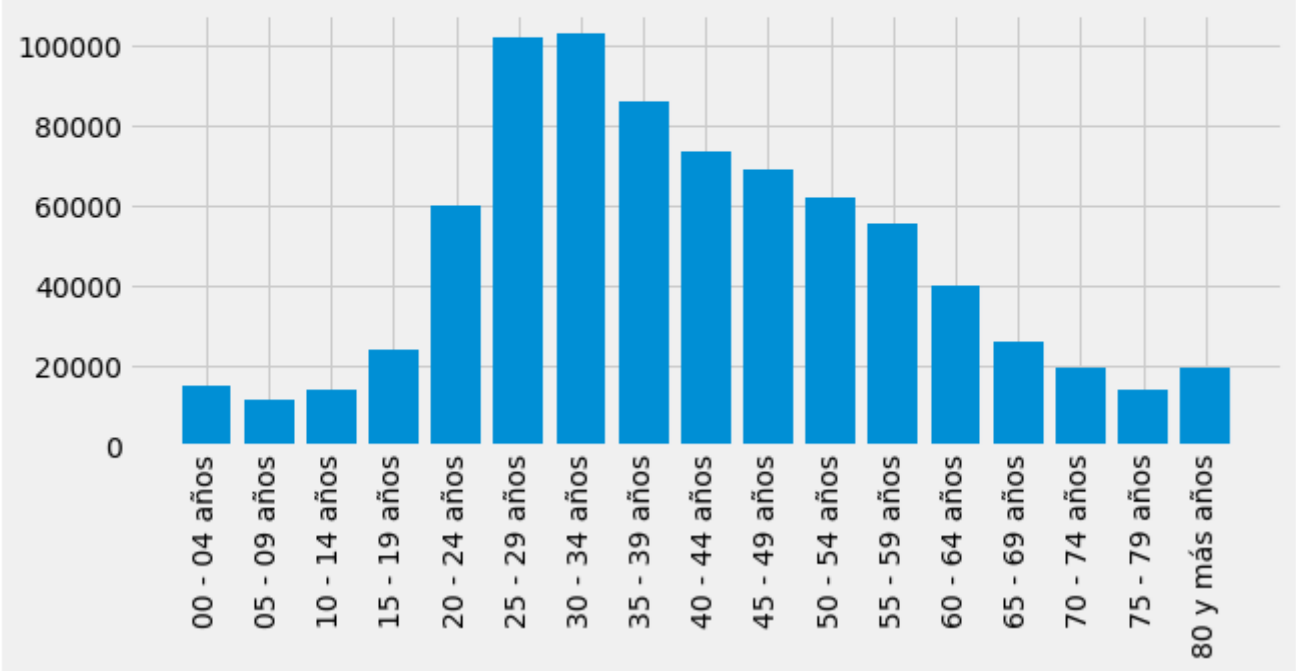

Estilos disponibles

```
plt.style.use('Solarize_Light2')
```

```
fig = plt.figure(figsize=(8,3))
axe = fig.add_axes([0,0,1,1])
axe.bar(df4['Grupo de edad'].values, df4['Contagiados'].values)
axe.tick_params(axis='x', labelrotation=90)
```

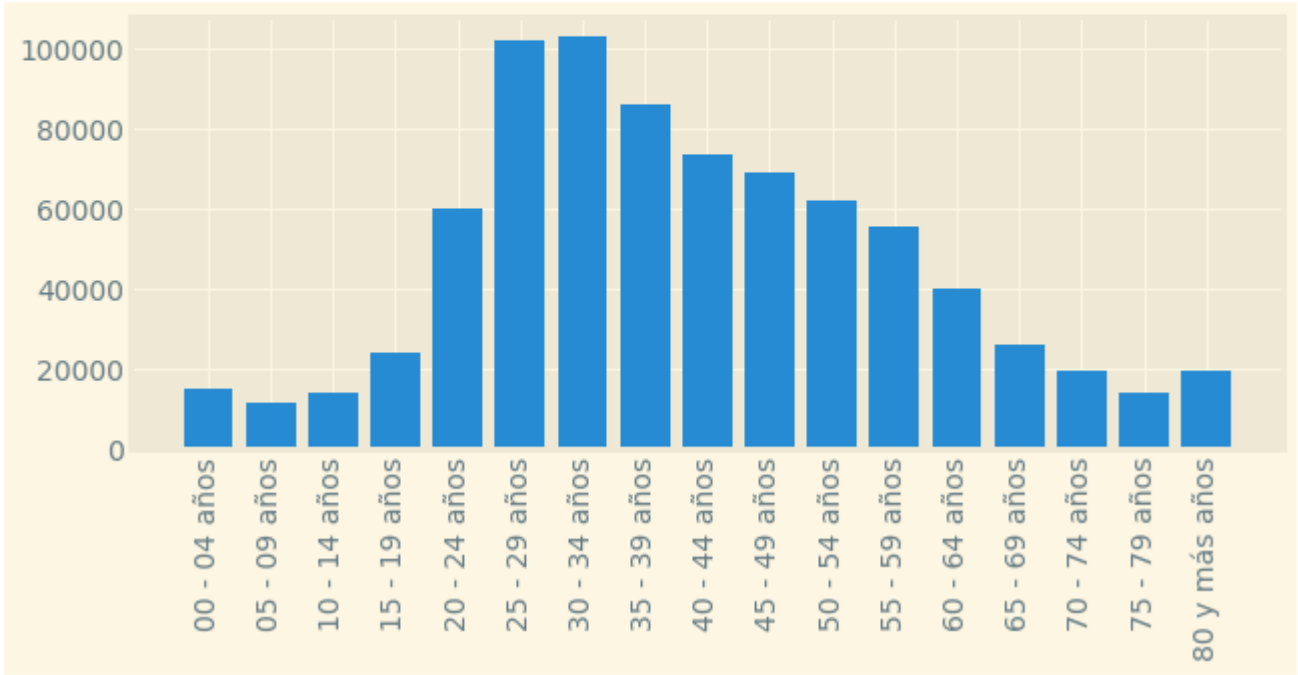

Estilos disponibles

```
plt.style.use('seaborn')
```

```
fig = plt.figure(figsize=(8,3))
axe = fig.add_axes([0,0,1,1])
axe.bar(df4['Grupo de edad'].values, df4['Contagiados'].values)
axe.tick_params(axis='x', labelrotation=90)
```

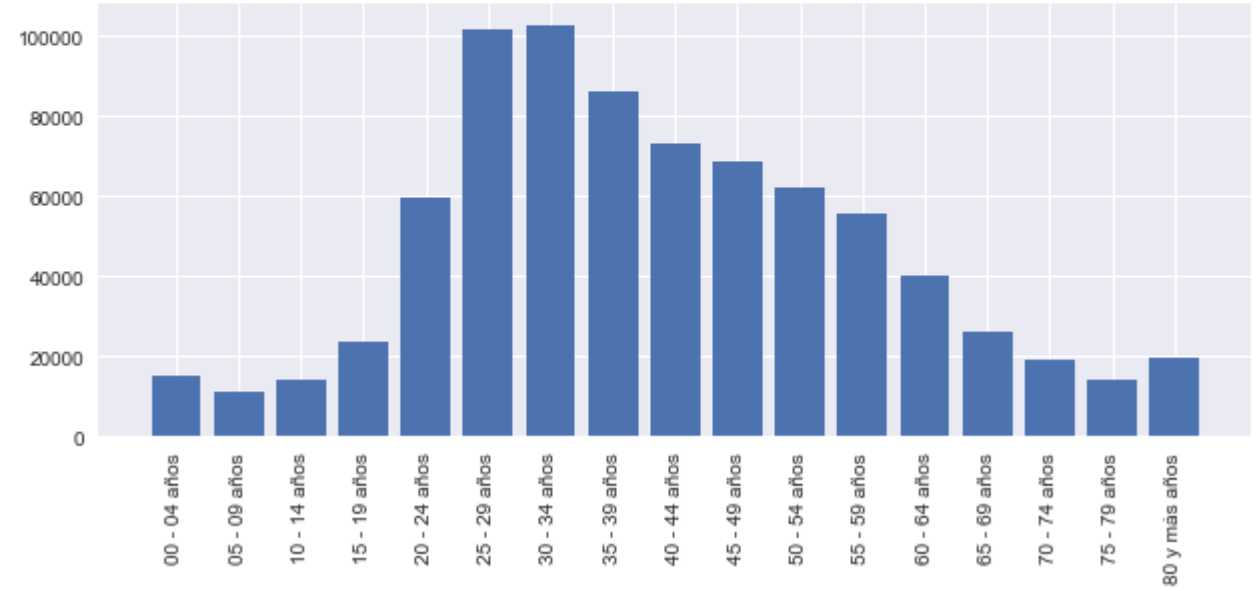

Estilos disponibles

```
plt.style.use('bmh')
```

```
fig = plt.figure(figsize=(8,3))
axe = fig.add_axes([0,0,1,1])
axe.bar(df4['Grupo de edad'].values, df4['Contagiados'].values)
axe.tick_params(axis='x', labelrotation=90)
```

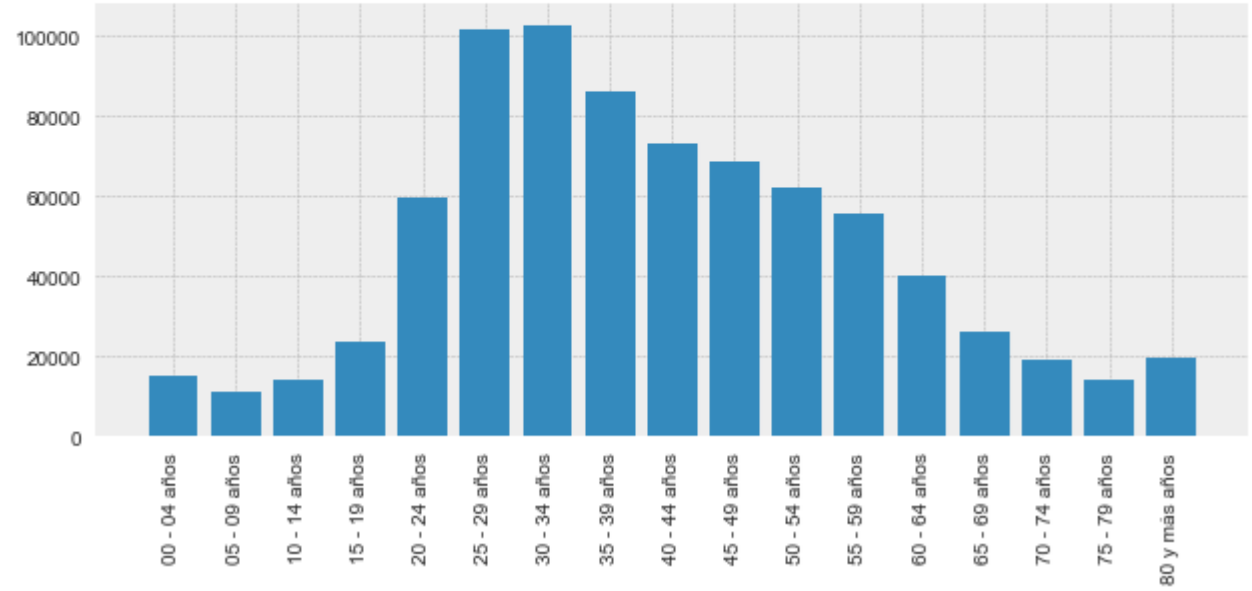

Estilos disponibles

```
plt.style.use('ggplot')
```

```
fig = plt.figure(figsize=(8,3))
axe = fig.add_axes([0,0,1,1])
axe.bar(df4['Grupo de edad'].values, df4['Contagiados'].values)
axe.tick_params(axis='x', labelrotation=90)
```

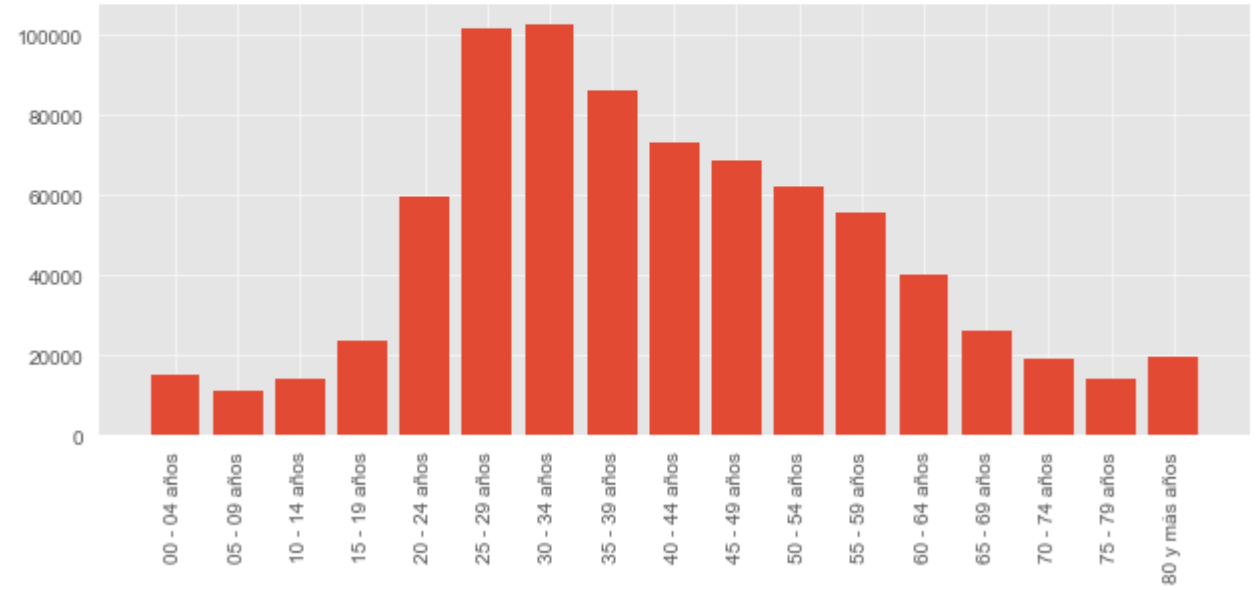

Dudas y consultas

KIBERNUM

Fin presentación

KIBERNUM